

Казанский (Приволжский) федеральный университет

Международная научная конференция

В. А. Богородицкий
и современная лингвистика

Казанский (Приволжский) федеральный университет

18–20 ноября 2024 г.

Труды и материалы

Том 2



КАЗАНЬ
2024

УДК 811.161.1
ББК 81.2Рус
В11

*Издается в рамках реализации мероприятий
Государственной программы
«Сохранение, изучение и развитие государственных языков
Республики Татарстан и других языков
в Республике Татарстан на 2023–2030 годы»
(Государственный контракт № 112 ЭА/2024)*

**Под общей редакцией
Р.Р. Замалетдинова, Е.А. Горобец,
Э.А. Исламовой**

В11 **В.А. Богородицкий и современная лингвистика:** труды и материалы международной научной конференции (Казань, 18–20 ноября 2024 г.): в 2 т. / под общ. ред. Р.Р. Замалетдинова, Е.А. Горобец, Э.А. Исламовой. – Казань: Издательство Казанского университета, 2024. – Т. 2. – 200 с.

ISBN 978-5-00130-877-5 (т. 2)
ISBN 978-5-00130-875-1

Во второй том трудов и материалов Международной научной конференции «В.А. Богородицкий и современная лингвистика» включены материалы докладов, заявленных на секции: «Проблемы сопоставительной лингвистики», «Текст и дискурс. Вопросы лингвокультурологии», «Лингводидактическое наследие Казанской лингвистической школы. Преподавание русского языка как иностранного», «Актуальные проблемы лексикологии и фразеологии», «Клиническая лингвистика и нейролингвистика. Русский жестовый язык», «В.А. Богородицкий и вопросы татарского языкознания».

УДК 811.161.1
ББК 81.2Рус

ISBN 978-5-00130-877-5 (т. 2)
ISBN 978-5-00130-875-1

© Издательство Казанского университета, 2024

Солнышкина Марина Ивановна¹

Андреева Мария Игоревна^{2,1}

Воронин Константин Валерьевич¹

¹ Казанский (Приволжский) федеральный университет

² Казанский государственный медицинский университет

УДК 81`42

Функционал RuLingva для анализа текстов РКИ

*учебный текст, РКИ, сложность текста,
текстовый профайлер, RuLingva*

Представленное исследование имеет целью продемонстрировать функционал автоматического анализатора RuLingva для профилирования текста РКИ, т.е. выявления характеристик текста. Известно, что учебные тексты, адресованные изучающим русский язык как иностранный, адаптированы, т.е. изменены «под читателя». Адаптация текста почти всегда предполагает изменение синтаксиса и лексики, сокращения и преобразования [Первухина 2014: 99]. Параметрический анализ текста оригинала и его адаптированного варианта помогает не только выявить изменения, производимые для того, чтобы текст стал понятен читателем, но и высвечивает спектр предикторов сложности текста. Известно, что первые попытки аналитики текстовых документов производились уже XVII в., когда католическая церковь ввела требование отслеживать долю нерелигиозных публикаций [Krippendorff 2004]. Современные инструменты для анализа текста и больших языковых данных многочисленны и имеют весьма широкий функционал [см. Kapiche; Research Software]. Недавний информационный взрыв повлек за собой новые методы разработки инструментов для анализа веб-страниц, блогов, книг, чатов и средств массовой информации [Neuendorf 2002]. При этом анализаторы обучающих текстов, по признанию экспертов, весьма востребованы разработчиками учебных и тестовых материалов, но при этом немногочисленны [Криони 2008]. Очевидно, что в качестве причин такого рода положения следует рассматривать, во-первых, отсутствие типологии учебных текстов, ранжированных по жанрам и уровням сложности, а во-вторых, небольшой размер учебного текста, не позволяющий осуществлять контент-анализ и профилирование методами, разработанными для больших объемов неструктурированных текстовых данных. Именно поэтому существующие анализаторы учебных текстов для русского языка, RuLingva (<https://rulingva.kpfu.ru/>) и Текстометр (<https://textometr.ru/>), продолжают

наращивать и расширять свой функционал. Анализаторы для учебных текстов на английском языке весьма многочисленны [English.com].

Автоматизированным анализом текста в представленном исследовании именуем основанный на использовании компьютерных методов анализ, имеющий целью установление его типа, жанра и регистра. Основная функция автоматических профайлеров учебных текстов – оценка соответствия текста заданной категории читателей [Solnyshkina 2024].

Рассмотрим возможности текстового анализатора RuLingva для использования его в учебном процессе. В качестве материала использованы адаптированные вторичные учебные тексты «Ионыч» (А. П. Чехов) и «Записки молодого врача» (М. А. Булгаков), а источниками послужили учебники РКИ [Николаева 2015; Антонова 2019].

В настоящее время RuLingva выполняет автоматический лингвистический анализ и рассчитывает метрики почти 80 параметров текстов на русском языке (см. Рис. 1а, 1б), включая количество предложений, словоформ, слов, слогов, лексическое разнообразие (отношение слов/словоформ), средняя длина предложения, индексы лексического разнообразия (TTR) и читабельности, связность, абстрактность, морфологические параметры и т. д.




Рис. 1а. Стартовый интерфейс RuLingva

Параметр		Значение
Количество токенов	i	494
Количество лемм	i	268
Лексическое разнообразие	i	0.54
Количество предложений	i	31
Средняя длина предложений	i	15.94
Количество слогов	i	1038
Средняя длина слов (в слогах)	i	2.1
Индекс Флеш-Кинкейда	i	10.03

Рис. 1б. Результаты анализа на платформе RuLingva

Отдельный интерес представляет формула читабельности учебных текстов, разработанная на основе формулы уровня Флеша-Кинкейда [Solovyev 2019].

Читабельность (рус.) = $208,7 - 2,6 \times SLS - 39 \times SDS$, где SLS – средняя длина предложения в словах, а SDS – средняя длина слова в слогах.

Формула читабельности ранжирует тексты по классам, т. е. в зависимости от года обучения, необходимого для прогнозирования доступности текста для среднестатистического читателя. Например, если рассчитанная читабельность составляет 7,5, текст адресован школьникам 7 или 8 классов, а если значение находится в диапазоне от 8,0 до 9,0, то – школьникам 8 и 9 классов и т. д.

RuLingva также позволяет осуществлять «грануляцию», т.е. рассчитывать метрики на предложение, абзац, документ или 1000 словоформ, а также сохранять данные в формате таблицы Excel (Рис. 2).

Результаты анализа					
№	Параметр	Документ	Абзац	Предложение	Нормализация на диапазон токенов [100 ▼]
Описательные параметры					
1	Количество словоформ	550	22.92	18.33	100
2	Количество лемм	311	12.96	10.37	56.55
3	Количество слогов	1217	50.71	40.57	221.27
4	Количество предложений	30	1.25	1	5.45
5	Среднее количество слов в предложении	18.33			
6	Среднее количество слогов в слове	2.21			
7	Среднее количество букв в слове	5.21			
8	Односложные слова	153	5.54	4.43	24.18
9	Двусложные слова	172	7.17	5.73	31.27
10	Трехсложные слова	113	4.71	3.77	20.55
11	Четырехсложные слова	52	2.17	1.73	9.45
Параметры читабельности					
12	Индекс Флеша-Кинкейда (SIS)	7.38			
13	Индекс Флеша-Кинкейда (O)	12.16			

Рис. 2а. Результаты анализа рассказа «Ионыч»

Результаты анализа					
№	Параметр	Документ	Абзац	Предложение	Нормализация на диапазон токенов [100 ▼]
Описательные параметры					
1	Количество словоформ	496	22.55	16	100
2	Количество лемм	268	12.18	8.65	54.03
3	Количество слогов	1045	47.50	33.71	210.69
4	Количество предложений	31	1.41	1	6.25
5	Среднее количество слов в предложении	16			
6	Среднее количество слогов в слове	2.11			
7	Среднее количество букв в слове	4.98			
8	Односложные слова	123	5.59	3.97	24.80
9	Двусложные слова	168	7.64	5.42	33.87
10	Трехсложные слова	98	4.45	3.16	19.76
11	Четырехсложные слова	44	2	1.42	8.87
Параметры читабельности					
12	Индекс Флеша-Кинкейда (SIS)	5.93			
13	Индекс Флеша-Кинкейда (O)	10.11			

Рис. 2б. Результаты анализа адаптации рассказа «Ионыч»

Как видим, читабельность данных текстов различается более, чем на два уровня: 7,36 в оригинале и 5,93 в адаптированном варианте. В целом результаты анализа дескриптивных параметров в значительной степени различаются (см. Рис. 2а, 2б).

Функция «Классификация слов по уровням» содержит информацию о количестве слов, классифицированных в соответствии с Обще-европейской шкалой уровней владения языком (A1–C2), а также отсутствующих в лексических минимумах.

Как видим, адаптированный вариант имеет значительно большую долю слов уровней A1, A2, B1, но меньше слов уровней B2, C1, C2. Несколько меньше в адаптированном варианте и слов, отсутствующих в лексических минимумах: 10.36, ориг. – 6.85, адап. (Рис. 3а, 3б).

RuLingva представляет и визуализацию долей лексики различных уровней сложности (см. Рис. 4а, 4б).

Каждое слово в тексте получает соответствующий тэг, позволяющий при подготовке к занятию или разработке предтекстовых упражнений осуществить замены на слова более низкого/высокого уровня

сложности или элиминировать слова, которые могут вызвать определенные сложности (Рис. 5а, 5б).

Уровень	Количество токенов	Количество лемм	Кумулятивная доля токенов	Кумулятивная доля лемм
A1	340 (61.82%)	131 (42.12%)	340 (61.82%)	131 (42.12%)
A2	23 (4.18%)	16 (5.14%)	363 (66.00%)	147 (47.27%)
B1	52 (9.45%)	48 (15.43%)	415 (75.45%)	195 (62.70%)
B2	53 (9.64%)	47 (15.11%)	468 (85.09%)	242 (77.81%)
C1	23 (4.18%)	19 (6.11%)	491 (89.27%)	261 (83.92%)
C2	2 (0.36%)	2 (0.64%)	493 (89.64%)	263 (84.57%)
UNL	57 (10.36%)	48 (15.43%)	550 (100.00%)	311 (100.00%)

Рис. 3а. Ранжирование лексики в рассказе «Ионыч» по уровням A1-C2

Уровень	Количество токенов	Количество лемм	Кумулятивная доля токенов	Кумулятивная доля лемм
A1	348 (70.16%)	144 (53.73%)	348 (70.16%)	144 (53.73%)
A2	23 (4.64%)	16 (5.97%)	371 (74.80%)	160 (59.70%)
B1	53 (10.69%)	47 (17.54%)	424 (85.48%)	207 (77.24%)
B2	31 (6.25%)	28 (10.45%)	455 (91.73%)	235 (87.69%)
C1	6 (1.21%)	6 (2.24%)	461 (93.94%)	241 (89.93%)
C2	1 (0.20%)	1 (0.37%)	462 (93.15%)	242 (90.30%)
UNL	34 (6.85%)	26 (9.70%)	496 (100.00%)	268 (100.00%)

Рис. 3а. Ранжирование лексики в адаптированном рассказе «Ионыч» по уровням A1-C2




Рис. 4а. Диаграмма ранжирования лексики рассказе «Ионыч»




Рис. 4б. Диаграмма ранжирования лексики в адаптированном рассказе «Ионыч»

(UNL) Иван (A1) Петрович (A1) и (A1) поцеловал (B1) её (A1) в (A1) лоб (A2) . - Вы (A1) очень (A1) кстати (B2) пожаловали (C1) , - обратился (B1) он (A1) опять (B1) к (A2) гостю (A1) , - моя (A1) благоверная (UNL) написала (A1) большой (UNL) роман (A1) и (A1) сегодня (A1) будет (A1) читать (A1) его (A1) вслух (B1) . - Жанчик (UNL) , - сказала (A1) Вера (A1) Иосифовна (UNL) мужу (A1) Старцеву (UNL) представили (B2) Екатерину (A1) Ивановну (UNL) , восемнадцатилетнюю (UNL) девушку (A1) , очень (A1) похожую (B1) на (A1) мать (A1) , такую (B1) же (B1) худощавую (C1) и (A1) милостивую (C1) . Выражение (C1) у (A1) неё (A1) было (A1) ещё (A1) детское (A1) и (A1) талия (C1) тонкая (B1) , нежная (B2) ; и (A1) девственная (UNL) , уже (A1) развитая (B2) грудь (B1) , красивая (A1) , здоровая (A1) , говорила (A1) о (A1) весне (A1) , настоящей (B2) весне (A1) . Потом (A1) пили (A1) чай (A1) с (A1) вареньем (B2) , с (A1) мёдом (B2) , с (A1) конфетами (B1) и (A1) с (A1) очень (A1) вкусными (A2) печеньями (A2) , которые (A1) таяли (C1) во (A1) рту (B1) . С (A1) наступлением (B2) вечера (A1) , мало-помалу (UNL) , сходились (C1) гости (A1) , и (A1) к (A2) каждому (A1) из (A1) них (A1) Иван (A1) Петрович (A1) обращал (B1) свои (A1) смеющиеся (A2) глаза (A1) и (A1) говорил (A1) : - Здравствуйте (A1) пожалуйста (A1) .

Рис. 5а. Разметка лексики по уровням сложности

Петрович (A1) и (A1) поцеловал (B1) её (A1) в (A1) лоб (A2) . - Вы (A1) очень (A1) кстати (B2) пришли (A1) , - обратился (B1) он (A1) опять (B1) к (A2) гостю (A1) , - моя (A1) жена (A1) написала (A1) большой (A1) роман (A1) и (A1) сегодня (A1) будет (A1) читать (A1) его (A1) вслух (B1) . - Жанчик (UNL) , - сказала (A1) Вера (A1) Иосифовна (UNL) мужу (A1) , Старцеву (UNL) представили (B2) Екатерину (A1) Ивановну (UNL) , восемнадцатилетнюю (UNL) девушку (A1) , очень (A1) похожую (B1) на (A1) мать (A1) , такую (B1) же (B1) худую (B1) и (A1) милую (B1) . Лицо (A1) у (A1) неё (A1) было (A1) ещё (A1) детское (A1) и (A1) талия (C1) тонкая (B1) , нежная (B2) , и (A1) красивая (A1) здоровая (A1) грудь (B1) говорила (A1) о (A1) весне (A1) , настоящей (B2) весне (A1) . Потом (A1) пили (A1) чай (A1) с (A1) вареньем (B2) , с (A1) мёдом (B2) , с (A1) конфетами (B1) и (A1) с (A1) очень (A1) вкусным (A2) печеньем (A2) . Вечером (A1) начали (A1) приходить (A1) гости (A1) , и (A1) к (A2) каждому (A1) из (A1) них (A1) Иван (A1) Петрович (A1) обращал (B1) свои (A1) весёлые (A1) глаза (A1) и (A1) говорил (A1) : Здравствуйте (A1) пожалуйста (A1) .

Рис. 5б. Разметка лексики по уровням сложности

Особого внимания заслуживают списки слов, отсутствующие в стандартизированных лексических минимумах, маркированные аббревиатурой UNL (см. Рис. 6).

Слова, отсутствующие в списках A1-C2	
pinse-nez (1)	► pinse-nez
бакен (1)	► бакенами
баловница (1)	► баловница
благверная (2)	► благоверной ► благоверная
большинский (1)	► большинский

Рис. 6. Лемматизированный список

Частотный профиль слова демонстрирует и визуализирует пользователю информацию о частотности слова в лексических списках-минимумах РКИ и словаре Шарова [Ляшевская 2009].




Рис. 7. Доли слов разной частотности в тексте «Записки молодого врача» (РКИ A2)

Заслуживающим внимания является конкордансер, программное обеспечение, выполняющее операцию поиска словоформы и отображающее все зарегистрированные в тексте случаи ее употребления [Захаров 2011]. Конкордансер позволяет расширять левый и правый контексты слова в пределах одного предложения.

Например,

отелло (1)	▼ Отелло
	• Мой муж ревнив, это Отелло, но ведь мы постараемся вести себя так, что он ничего не заметит.

Рис. 8. Контекст слова Отелло в рассказе «Ионыч»

Конкорданс как один из инструментов учебной и исследовательской деятельности весьма может быть использован для сравнения дистрибуции слова, анализа ключевых слов, анализ частотности слов и словосочетаний, идиом, а также для создания списков слов.

RuLingva также позволяет выгружать текст с полной морфологической разметкой и группировать слова из текста по частям речи (Рис. 9).




Рис. 9. Морфологическая разметка

Результаты многочисленных исследований показали, что RuLingva позволяет классифицировать типы текстов (например, информационные и учебные) с помощью ограниченного списка параметров. Действующий функционал RuLingva может применяться в различных областях, включая поисковые системы, где автоматическая классификация текста имеет первостепенное значение. Ее также могут использовать специалисты по текстовой аналитике, преподаватели, разработчики тестов, а также авторы учебников и журналисты.

Благодарности

Исследование выполнено при финансовой поддержке РНФ, грант 24-78-10129 «Когнитивная и лингвистическая сложность текста».

Литература

Антонова В. Е. Дорога в Россию: учебник русского языка (базовый уровень) / В. Е. Антонова, М. М. Нахабина. 14-е изд. СПб.: Златоуст, 2019. 256 с.

Захаров В.П. Корпусная лингвистика: учеб. для студентов гуманитарных вузов / В. П. Захаров, С. Ю. Богданова. Иркутск: ИГЛУ, 2011.

Криони Н. К. Автоматизированная система анализа сложности учебных текстов / Н. К. Криони, А. Д. Никин, А. В. Филиппова // Вестник Уфимского государственного авиационного технического университета. 2008. Т. 11. № 1. С. 101–107.

Ляшевская О. Н. Частотный словарь современного русского языка (на материалах Национального корпуса русского языка) / О. Н. Ляшевская, С. А. Шаров. М.: Азбуковник, 2009. URL: <http://dict.ruslang.ru/freq.php>. (дата доступа: 14.11.2024)

Николаева Ю. В. А. П. Чехов. Ионыч / Ю. В. Николаева. Златоуст; Санкт-Петербург, 2015.

Первухина С. В. Виды адаптации текста / С. В. Первухина // Вестник Южно-Уральского государственного университета. Серия: Лингвистика. 2014. Т. 11. № 1. С. 97-100.

English.com URL: <https://www.english.com/gse/teacher-toolkit/user/textanalyzer> (дата доступа: 14.11.2024)

Kapiche. URL: <https://www.kapiche.com/blog/text-analytics-tools> (дата доступа: 14.11.2024)

Krippendorff K. Content Analysis: An Introduction to Its Methodology / K. Krippendorff. Thousand Oaks, CA: Sage, 2004.

Neuendorf K. A. The Content Analysis Guidebook / K. A. Neuendorf. Thousand Oaks, CA: Sage, 2002.

Research Software. URL: <https://www.qresearchsoftware.com/how-to-automatically-code-unstructured-text-data-in-q> (дата доступа: 14.11.2024)

Solnyshkina M. I. Linguistic profiling of text genres: adventure stories vs. textbooks / M. I. Solnyshkina, R. V. Kupriyanov, G. N. Shoeva // Научный результат. Вопросы теоретической и прикладной лингвистики. 2024. Т. 10. № 1. С. 115–132.

Solovyev V. Prediction of Reading Difficulty in Russian Academic Texts / V. Solovyev, M. Solnyshkina, V. Ivanov, I. Batyrshin // Journal of Intelligent & Fuzzy Systems. 2019. Vol. 36. Issue 5. Pp. 4553–4563.